

Laboratorio ETL con Scrapy y SQLite

Extraccion, transformacion, almacenamiento y consulta de datos

1. Objetivo

Construir un proceso ETL que extraiga informacion de libros y productos tecnologicos, transforme los datos y los almacene en una base de datos SQLite relacional para realizar consultas analiticas.

2. Fuentes exploradas


Fuente	Informacion	Registros
Books to Scrape	Libros, precio, calificacion, categoria, disponibilidad y descripcion.	1.000 libros
Web Scraper Test Sites	Laptops, precio, calificacion, categoria y descripcion.	117 productos

La informacion comun entre ambas fuentes es nombre, precio, calificacion y URL. Categoria, descripcion y disponibilidad dependen de cada sitio.

3. Extraccion y transformacion

Los spiders BooksSpider y LaptopsSpider recorren las paginas disponibles y guardan los resultados en archivos JSON. La transformacion elimina espacios innecesarios, convierte precios y calificaciones a tipos numericos, normaliza disponibilidad, identifica valores faltantes y elimina duplicados por fuente y URL.

4. Modelo de base de datos



Fuentes se relaciona con productos. Productos contiene los atributos comunes y se especializa en tecnologia o libros. Libros se relaciona con categorias.

5. Consultas SQL y resultados

Consulta	Resultado
1. Producto junto con fuente	Relaciona productos con fuentes mediante id_fuente.
2. Informacion de categorias	Relaciona libros, productos y categorias mediante claves foraneas.
3. Productos por tipo	libro: 1.000; tecnologia: 117.
4. Producto mas costoso	Asus ROG Strix SCAR Edition GL503VM-ED115T: 1799.00.
5. Producto mas economico	An Abundance of Katherines: 10.00.
6. Precio promedio	126.65.
7. Calificacion promedio	2.86.
8. Fuente con mas productos	Books to Scrape: 1.000 productos.

6. Validacion

Indicador	Resultado
Productos totales	1.117
Registros en libros	1.000
Registros en tecnologia	117
URLs duplicadas	0
Productos sin nombre o URL	0
Errores de claves foraneas	0

Archivos principales: etl/spiders.py, etl/transform.py, etl/database.py, etl/schema.sql, etl/queries.sql, etl/run.py y etl.db.